Xilinx Zynq FPGA,TI DSP, MCU 기반의 프로그래밍 전문가 과정

날 짜 : 2018 . 4. 10

강사 – Innova Lee(이상훈)
gcccompil3r@gmail.com
학생 – 정한별
hanbulkr@gmail.com

< 리눅스 커널 내부 구조_ Chapter_ 3>

1. 실시간 태스크 스케쥴링(FIFO, RR , DEADLINE)

- CPU 를 어떤 태스크가 사용하도록 해줄 것인가? 공정해야 여러 태스크들이 불평하지 않을 것이다.

- 스케쥴러의 역할이 효율적이어야 가장 높은 처리율을 낼 수 있다. 가장 급한 태스크를 한가한 태스크보다 먼저 수행될 수 있도록 해준다면 보다 높은 반응성을 보일수 있다.

- 위의 3 가지 정책중에 deadline 정책을 주로 사용한다고 보면 된다.

- 실시간 태스크는 우선순위 설정을 위해 task_struct 구조체의 rt_piriority 필드 사용.
(0~99 까지의 우선순위), (100~139 는 일반 태스크)

→커널은 하이브리드 방식을 가져서 여러가지 스케쥴링을 한다.

- RR 방식은 번갈아가며 공정하게 동작하는 방식인데, 기본적으로 우선순위를 고려한 동작방식이다.
(동일 우선순위에 따라 time slice 기반으로 동작한다. 동일우선순위가 없을 때 , FIFO 와 동일 하다.)

- 시스템에 존재하는 모든 태스크는 tasklist 라는 이중 연결 리스트에 연결되어 시스템내 모든 task 접근 가능.

- 하지만 위와 같은 연결은 문제가 있다. 태스크의 개수가 늘어나면 그만큼 스케줄링에 걸리는 시간도 선형적으로 증가하며 (O(n)의 시간복잡도), 따라 스케쥴링 시간의 예측이 불가능 하다.

O(n)의 시간 복잡도

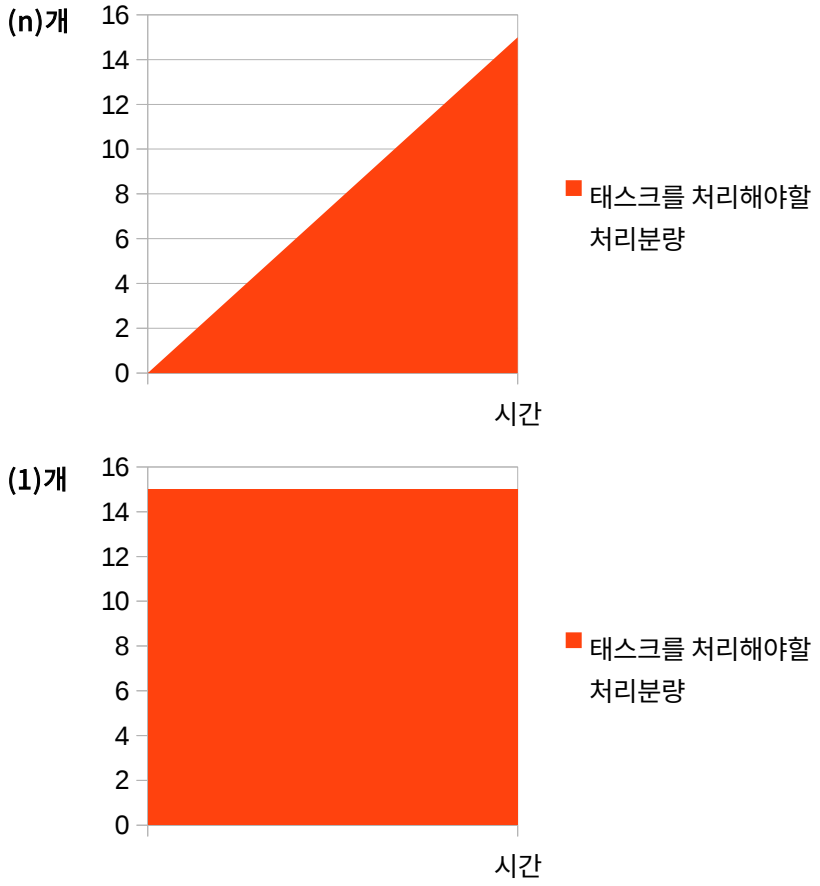

1. 위의 단점을 해결 하기 위해서, 태스크는 0~99 의 우선순위 레벨에 맞는 비트맵을 생성한다.
2. 비트맵에서 그 태스크의 우선순위에 해당하는 비트를 1 로(나중에 '&' 연산으로 check) set 한 뒤 해당하는 우선순위 큐에 삽입한다.
3. 스케줄링 하는 시점이 되면 커널은 비트맵에서 가장 처음으로 set(우선순위높은) 된 비트를 찾아 선택한다.
4. 비트맵에서 최우선 비트를 찾아내는 것은 상수시간 안에 가능함으로 고정시간 내 완료된다.

- 비트맵을 가지고 queue 에 넣는게 hash table 이다.

*deadline 정책

기존 리눅스의 실시간 태스크 스케줄링 정책은 우선순위에 기반하여 스케줄링 대상을 선정하는데 반해 , deadline 정책은 잠시 후 설명될 deadline 이 가장 가까운 (즉 가장 급한) 태스크를 스케줄링 대상으로 선정한다.

예를 들어 동영상을 재생하는 태스크가 수행중 이라고 가정하자.
초당 30 프레임을 디코딩 하여 화면에 출력하면 태스크는 1 초당 30 번 씩 '해야하는 일' 을 가지고 있는 것이다.
이 때, (1 초/ 30)보다는 적은 시간내에 수행해야할 '작업량' 을 가질 수 있음을 의미한다.
여기서 '초당 30 회' 는 period 라고 부르고 '작업량' 은 runtime, '완료시간' 을 DEADLINE 이라고 한다.

이 DEADLINE 정책을 사용하는 각 태스크들은 deadline 이용하여 RBTree 에 정렬되어 있으며, 스케줄러가 호출되면 가장 가까운 deadline 을 가지는 태스크를 스케줄링 대상으로 선정한다. 즉 우선순위가 상관없다.
(영상, 음성, 스트리밍 등, 제약 시간을 가지는 수많은 응용들에 용이하다.)

*커널 내에서 (vi -t 로 들어간 직후, kernel 디렉토리에서) driving 하며 찾을 때, 명령어
:cs find 0 '파일이름'

2. 일반 태스크 스케줄링(CFS)

-- 가상적으로 공평하게 , 실제시간으로 공평하게 한다. –

완벽하게 공정한 스케줄링, cpu 사용시간에서 공평한 분배를 의미한다. A, B 두 태스크가 있다면 사용시간이 1:1 로 같아야 한다.
시간이 항상 1:1 일 수는 없다. CFS 는 정해진 '시간단위' 로 봤을 때, 공정한 시간을 할당하는 것을 목표한다.
1 초를 시간단위로 하면 0.5 초는 A 태스크가, 0.5 초는 B 태스크가 동작 함으로써 A 와 B 의 사용시간이 1 초간 1:1 이 되도록 하는 것이다.
즉 런큐에 n 개의 태스크가 존재하면 '시간단위' 를 n 으로 나누어 n 개의 태스크에게 할당해 주면 된다.

*여기서 우선순위 높은 태스크게 가중치를 둔다면 우선순위가 높은쪽에 가중치를 높인다.

- 이를위해 리눅스는 vruntime 을 만들었다.
(우선순위가 높은 것은 시간을 많이 가져야 하는데 그래서 곱해지는 가중치가 적어야 한다.)

vrntime += physicalruntime * weight(0)/ weight(curr)
(**weight(curr)**: 현재 태스크의 weight 값을 의미, **weight(0)** : 기본 단위인 1024)

- 스케줄링이 되는 대상을 빠르게 골라내는 방법은 가장 작은 vruntime 값을 가지는 태스크가 가장 과거에 cpu 를 사용 했음을 의미 한다.
따라서, RBTree 는 맨 왼쪽에 작은 값이 오는 규칙을 이용해 금방 찾아 낼 수 있다.

- 위의 다음 문제로 vruntime 값이 항상 작은 값으로 스케줄링 된다면 너무 자주 스케줄링이 발생하지 않을까?
Context switching 을 줄이려면 time slice 를 최대한 사용한다.

- 스케줄러는 언제 호출될까?(nice system call)
1. schedule() 함수를 호출하는 방법
2. thread_info 구조체 내부에 존재하는 flags 필드중 need_resched 라는 필드를 설정.

- (그룹: 특정 사용자)간의 스케줄링은 공정하게 그룹 1 초, 특정사용자 1 초 식으로 cpu 가 공정하게 분배를 한다.

Chapter 4

1. 물리 메모리 관리 기법과 가상 메모리

- 사용자는 물리적으로 존재하는 메모리 보다 더 많은 양의 메모리를 필요로함, 그래서 많은 기법들이 개발되었다.
그 중에서 가장 성공적이고 지금도 대중적인 방법이 가상 메모리 이다.

- 어차피 가상적으로 주는 공간이라면 되도록 많은 공간을 준다. 32 비트의 cpu 의 경우 4GB 의 가상 주소 공간을 사용자에게 제공 한다. 64 비트의 경우는 Exa Byte 의 크기를 할당 할 수 있다. (너무큼)

- 한가지 주의할 점은 4GB 모두 사용자에게 제공하는 것이 아니다. 그저 개념적으로 제공되는 가상 공간이다.
실제로는 사용자가 필요한 만큼의 물리 메모리를 제공한다. (커널에 sys_exceve 가 물리메모리로 가져옴)

- 필요한 만큼의 물리메모리 사용으로 많은 태스크가 동시에 사용 가능, 커널이 메모리 배치를 알아서 하기 때문에 배치 정책이 불필요 하다.

2. 물리 메모리 관리 자료 구조

- 처음 부팅시 전체 물리 메모리에 대한 정보를 가지고 온다.

- 물리적 자원이 리눅스에서 어떻게 표현되는지는 (paging, slab, uma, numa 등이 있다.)

- 요즘 이기종 시스템(NUMA)은 CPU 를 몇 개의 그룹으로 나누어 메모리 입출력 버스간 공유(SMP)에서 병목 현상이 일어나는 것을 줄이기 위해 사용하는 기법이다.

- UMA 구조는 BANK 1 개 가지고 있다. NUMA 구조는 BANK 2 개 이상으로 CPU 에서 어떤 메모리에 접근하느냐에 따라 속도가 달라진다, 되도록 가까운 메모리에 접근해야한다.

2-1 Node

- 접근속도가 같은 메모리의 집합을 뱅크(bank)라 부른다. 리눅스에서 bank 를 표현하는 구조가 'node' 이다.

- UMA 의 경우 한개의 node 가 존재할 것이다. 이 node 는 contig_pagedata 를 통해 접근 가능하다.

- NUMA 의 경우 복수개의 node 가 존재할 것이다. 복수개 node 는 list 를 통해 관리되며 pglist_data 라는 배열을 통해 접근이 가능하다.

- 위 contig_pagedata , pglist_data 는 물리메모리 실제양, 물리메모리 맵핑 위치 등의 정의 되어 있다.

- 리눅스가 물리메모리 할당 요청을 받으면, 되도록 할당 요청한 태스크(cache 를 쓴단 의미)가 수행되고 있는 cpu 와 가까운 node 에서 메모리를 할당하려 한다.

*cache 는 자주 쓰는것들이나 빨리 써야 하는 것들을 저장하는 공간이다. 빠르게 읽고 쓰기가 가능하다.

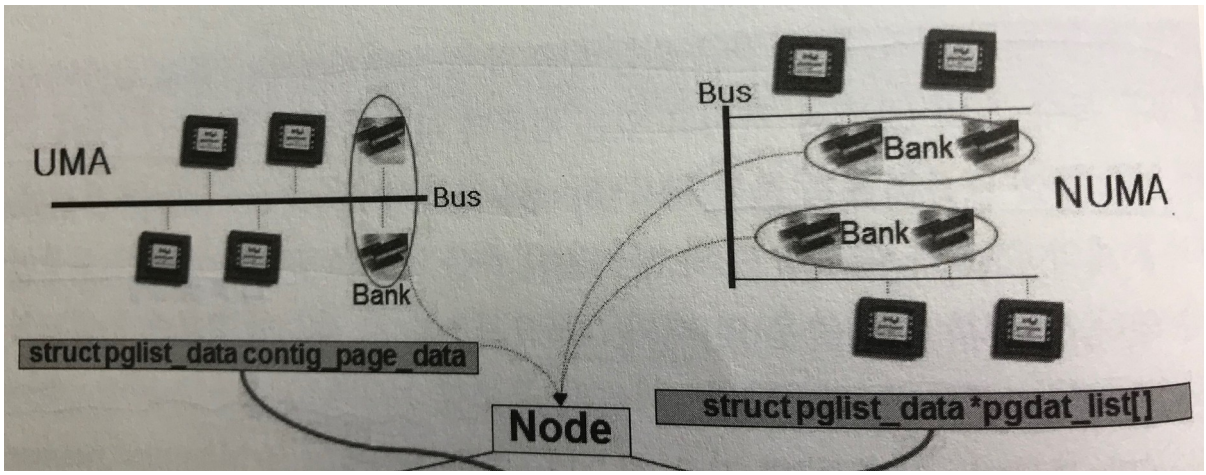

2-2 Zone

- node 안에 존재 하고 있는 물리 메모리는 모두 어떤한 용도로도 사용될 수 있어야 한다. 그 결과 node 에 존재 하는 물리메모리중 16MB 이하 부분을 좀 특별하게 관리 한다.

- 이를 위해 node 의 일부분을 따로 관리 할 수 있도록 자료구조를 만들어 놓았다.

- zone 은 동일한 속성을 가지나, 다른 zone 의 메모리와는 별도로 관리되어야 하는 메모리의 집합이다.

- ZONE_DMA (direct memory access) 0~16M → cpu 에 거치지 않고 memory 에 접근 한다.
(서버,비디오, 사운드→ V4L2 , ALSA(코덱만드는 기술))

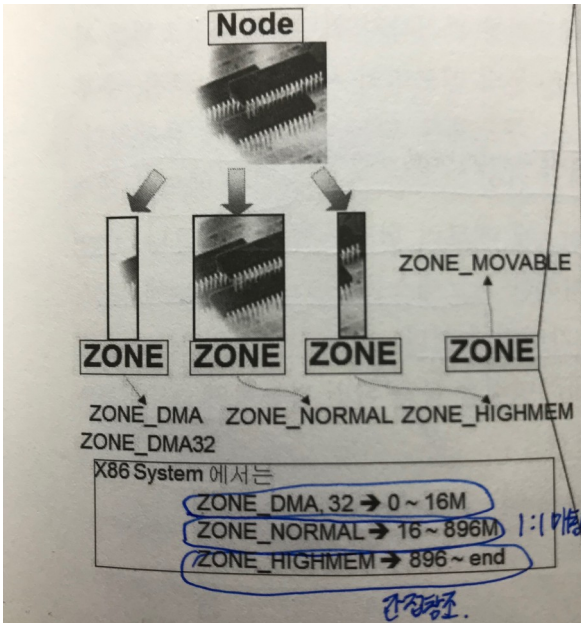

- ZONE_NORMAL (16~ 896M) → 1 대 1 로 매칭해 저장하는 공간.

- ZONE_HIGHMEM (896 ~ end) → 동적으로 연결하여 사용할 수 있는 간접 참조 구조

- 64bit 운영 체제는 공간이 워낙 많기 때문에 위의 3 가지 형태의 존이 다 있지 않고 1:1 매칭만 으로도 가능하다.

- zone 구조체는 free_area 를 가지고 있는데 버디 할당자가 사용하는 영역이다.

- zone 에는 watermark , vm_stat 을 통해 빈 공간이 부족시 적절한 메모리를 해제를 한다.
1. watermark : 워터마크가 표시된 곳을 넘어가면 해제 하는 옵션.
2. vm_stat : 현재 상태를 가지고 있다.

2-3 Page frame

- 물리 메모리의 최소 단위 이다. page 는 이 page_frame 을 관리 하는 소프트웨어 이다.

- page 구조체는 kmem_cache *slab_cache 라는 슬렙 할당자를 가지고 있다.

- page_frame 하나당 page 구조체가 존재한다.

- page 구조체는 4kbyte 가 나오면 안된다. 다른정보도 저장해야 하니까. 더 작아야 한다.

- 부팅되는 순간에 구축이 된다. 이 위치는 mem_map 이라는 전역 배열을 통해 접근 된다.(node→ pglist_data)
(mem_map 은 디스 콘티그가 없으면 노드는 '0' 하나다.)

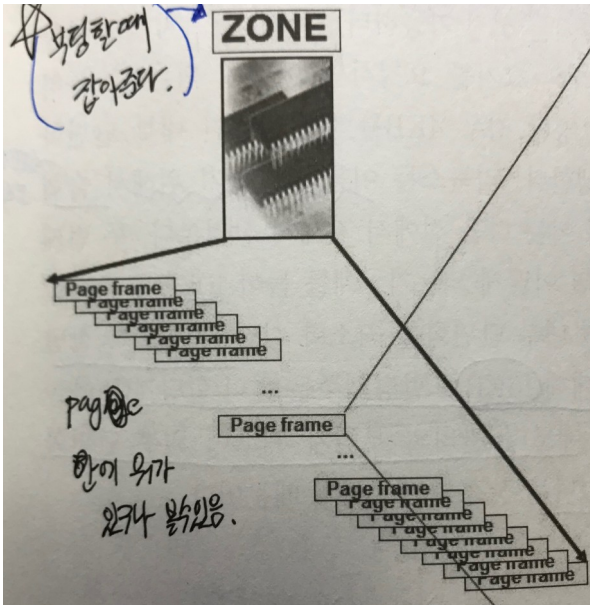

3 Buddy 와 Slab

- 사용자가 1byte 가 필요시 1byte 단위로 할당해 버리면 이를 관리하는 메타데이터가 넘어 서기 때문에 1byte 보다 큰 양을 할당해야 한다.

- 페이지 프레임 단위 (4kB) 로 할당 하도록 결정 한 방식이 Buddy 이다. (4KB x 2^n 방식으로 동작)

- 만약 작은 단위로 크기를 요청 해줄 경우 (30byte 나 60 byte 정도) 4KB 를 할당 하면 내부 단편화가 올 수 있다.
이를 해결 하기 위해 Slab 할당자를 이용한다. 4KB 에서 2^n 으로 쪼개서 사용하는 방식이다.

3-1 Buddy 버디 할당자(소프트웨어 로직)

- buddy 는 zone 당 하나씩 존재 한다.

- zone 구조체에 존재하는 free_area[] 배열을 통해 구축 되며 그 안에는 free_list 와 nr_free 라는 필드를 갖는다.
    1. free_list : 비어있는 리스트
    2. nr_free : 얘가 몇개 비어 있나 알려준다. (비사용중인 페이지 프레임 개수)

- 리눅스 구현상 최대 할당 크기는 (2^9 x 4KB) 이다.

- 외부 단편화를 해주었다.

- 몇 K 가 나오든 나누어 주기가 편하다.

- 한번 하면 두번 다시 페이지를 못한다. 하지만 덕분에 빠르다.

3-2 Lazy Buddy (소프트웨어 로직)

- 기존 버디의 문제점이 있어서 만들게 되었다.

- 한 페이지 프레임을 할당/해제 반복하는 경우.
페이지 할당을 위해 페이지를 slab(쪼개서) 할당해 주어야 한다. (비트맵 수정해야함) 그리고 할당을 해제 하면 다시 큰 페이지로 합쳐 지면서 (비트맵이 수정되야함) 다시 큰 페이지로 돌아온다.
이 것이 반복이 되면서 할당 해제를 위해 오버 헤드가 동반된다.

→ 할당된 페이지를 구태여 바로 다시 합치지 말고 곧 다시 할당 되는 것을 생각해 작업을 뒤로 미룬다.

→ zone 에 있는 watermark 를 페이지 가능 수를 비교 후 zone 메모리가 충분 시 병합을 뒤로 미룬다. 가용메모리가 부족 시에 해제 한다.

* 버디 할당 관련 정보 : cat /proc/buddyinfo

3-3 슬랩 할당자 (소프트웨어 로직)

- 내부 단편화를 없애 주었다.

- 우리는 자료구조에서 32byte 씩 했다 그래서 느려졌다. 새로 쪼개야 하기 때문에…

1. 페이지 프레임 을 받아서 이 공간을 나눈다.
2. 그리고 버디할당자로 부터 받지 말고 나뉜 공간으로 받는다.
3. 해제시에는 버디로 반납하는게 아닌 미리 할당 받은 공간에 그대로 가지고 있는다.
4. 일종의 캐시로 사용하는 것이다.

→ 이런 캐시 집합을 통해 메모리를 관리하는 정책을 slab 할당자라고 한다.
(kmem_cache)→(kmem_cache_node) *slab_cache

- kemem_cache 를 위한 공간을 할당받아 다양한 캐시를 생성할 수 있게 되는 것이다.

- 슬랩 할당자는 외부 인터페이스 함수로 kmalloc()/kfree()를 제공 한다.
kmalloc() : 메모리를 순차적으로 배치 cache 의 locality (지역성),
최대 128k~4MB 할당된 공간은 연속(순차적 배치) 특징으로 빠르다.

4 가상 메모리 관리 기법